

SUPPORT DE COURS PROBA-STAT

ENSEIGNANT : Dr TAKI

07 07 73 84 16

CHAPITRE I

PROBABILITE

LECON 1 : ANALYSE COMBINATOIRE-NOTION DE PROBABILITE

LECON 2 : VARIABLES ALEATOIRES. LOIS DE PROBABILITE

1. Variables aléatoires

D é f i n i t i o n 1

Soit une expérience aléatoire dont l'ensemble fondamentale est Ω . On appelle variable aléatoire X associée à cette expérience, toute fonction à valeurs réelles, définie sur Ω . L'ensemble des valeurs prises par X est noté $X(\Omega)$.

D é f i n i t i o n 2

On dit que X est une variable aléatoire discrète, si $X(\Omega)$ est un ensemble fini et X est une variable aléatoire continue, si $X(\Omega)$ est un intervalle de $\mathbb{R}$.

Exemples

- 1) On lance une pièce de monnaie 3 fois. On a

$$\Omega = \{PPP, FFF, PPF, PFF, FPP, FPF, PFP, FFP\}$$

X désigne le nombre de "pile" obtenu au cours des 3 jets. On obtient

$$X(\Omega) = \{0, 1, 2, 3\}$$

X est une variable aléatoire discrète.

- 2) Soit l la taille des élèves de la classe. Alors $l = l_0 \pm \delta = [l_0 - \delta, l_0 + \delta]$.
 l est une variable aléatoire continue.

2. Variables aléatoires discrètes

a. Définitions

Définition 3

Si les valeurs prises par une variable aléatoire X forment une série discrète de nombres $x_1, x_2, \dots, x_n$, cette variable aléatoire est appelée variable aléatoire discrète et

$$X(\Omega) = \{x_1, x_2, \dots, x_n\}.$$

Exemple

On lance une pièce de monnaie 3 fois. On a

$$\Omega = \{PPP, FFF, PPF, PFF, FPP, FPF, PFP, FFP\}$$

X désigne le nombre de "pile" obtenu au cours des 3 jets. On obtient

$$X(\Omega) = \{0, 1, 2, 3\}$$

Définition 4

On appelle loi de probabilité ou loi de distribution d'une variable aléatoire discrète X , la relation entre les valeurs possibles de X et leur probabilité.

Remarques

1) La loi de probabilité de X est donnée par :

$$X(\Omega) = \{x_1, x_2, \dots, x_n\} \text{ et la probabilité } P\{X = x_i\} = P_i, i = 1, 2, \dots, n$$

avec :

- $P_i \geq 0$;
- $\sum_{i=1}^n P_i = 1$.

2) La loi de probabilité est souvent représentée par un tableau

X	x_1	x_2	$\dots$	x_n	
$P\{X = x_i\}$	P_1	P_2	$\dots$	P_n	$\sum P_i = 1$

Exemple

On lance une pièce de monnaie 3 fois. On a

$$\Omega = \{PPP, FFF, PPF, PFF, FPP, FPF, PFP, FFP\}$$

X désigne le nombre de "pile" obtenu au cours des 3 jets. On obtient

$$X(\Omega) = \{0, 1, 2, 3\}$$

Loi de probabilité de X

X	0	1	2	3
$P\{X = x_i\}$	1/8	3/8	3/8	1/8

b. Fonction de répartition

Définition 5

On appelle fonction de répartition de la variable aléatoire discrète X, la fonction F :

$$F : \mathbb{R} \rightarrow [0, 1]$$

$$x \rightarrow F(x) = P\{X \leq x\}.$$

Remarque

$$F(x) = P\{X \leq x\} = \sum_{x_i \leq x} P(x_i)$$

Exemple

D'après le tableau précédent

$$F(x_1) = P\{X \leq x_1\} = P_1 ;$$

$$F(x_2) = P\{X \leq x_2\} = P\{X = x_1\} + P\{X = x_2\} = P_1 + P_2 ;$$

.....

$$F(x_n) = P\{X \leq x_n\} = P\{X = x_1\} + P\{X = x_2\} + \dots + P\{X = x_n\} = P_1 + P_2 + \dots + P_n = 1$$

Propriétés

- 1) F(x) est monotone, croissante de 0 à 1, avec $F(-\infty) = 0$ et $F(+\infty) = 1$.
- 2) F(x) est constante par intervalle . Sa représentation graphique a la forme d'un diagramme en escalier.
(Figure)

c. Espérance mathématique

Définition 6

On appelle espérance mathématique de la variable aléatoire X, on note E(X), l'expression :

$$E(X) = x_1P(x_1) + x_2P(x_2) + \dots + x_nP(x_n)$$

On a $P(x_i) = P_i$, d'où

$$E(X) = x_1P_1 + x_2P_2 + \dots + x_nP_n$$

ou

$$E(X) = \sum_{i=1}^n x_i P_i .$$

Remarque

E(X) caractérise la valeur moyenne de la variable aléatoire X.

Exemple

Dans l'exemple précédent,

$$E(X) = 0.1/8 + 1.3/8 + 2.3/8 + 3.1/8 = 3/2$$

d. Variance. Ecart-type

Définition 7

On appelle variance ou dispersion de la variable aléatoire X , on note $V(X)$, l'expression :

$$V(X) = \sum_{i=1}^n [x_i - E(X)]^2 P(x_i) .$$

Remarque

On a

$$V(X) = E(X^2) - [E(X)]^2 .$$

Définition 8

On appelle écart-type de la variable aléatoire X , on note $\sigma(X)$, l'expression :

$$\sigma(X) = \sqrt{V(X)} .$$

Exemple

Dans l'exemple précédent, calculons $V(X)$. On a

$$E(X^2) = \sum_{i=1}^n x_i^2 P_i ,$$

d'où

$$E(X^2) = 0^2.1/8 + 1^2.3/8 + 2^2.3/8 + 3^2.1/8 = 3$$

$$[E(X)]^2 = (3/2)^2 = 9/4,$$

Et

$$V(X) = E(X^2) - [E(X)]^2 = 3 - 9/4 = 3/4$$

3. Variables aléatoires continues

a. Définitions

Définition 9

On dit que X est une variable aléatoire continue, si les valeurs prises par X appartiennent à un intervalle de $\mathbb{R}$:

$$X(\Omega) = [a, b] \subset \mathbb{R} .$$

Remarques

- 1) Tous les processus de mesure conduisent à des variables aléatoires continues :
 - La durée de fonctionnement d'un dispositif technique
 - La taille , le poids, la température, etc ...
- 2) Si X est une variable aléatoire continue, la probabilité que X prenne une valeur quelconque isolée est nulle. Il n'est donc pas possible de définir une loi de probabilité comme pour une variable aléatoire discrète.

Définition 10

On appelle fonction de densité de probabilité, la fonction $f(x)$ telle que :

- 1) $f(x) \geq 0$;
- 2) $\int_{-\infty}^{+\infty} f(x) dx = 1 .$

Remarque

Si $f(x)$ est une fonction de densité de probabilité (f.d.p.), alors

$$P\{a < X < b\} = \int_a^b f(x)dx .$$

Exemple

Soit une f.d.p. $f(x)$ définie par

$$f(x) = \begin{cases} 0 & , \text{ si } x < 0 \\ x - \frac{x^3}{4} & , \text{ } 0 \leq x \leq 2 . \\ 0 & , \text{ } x > 2 \end{cases}$$

Calculer

1) $P\{-2 < X < 3\} ?$

2) $P\{X > -2\} ?$

1) $P\{-2 < X < 3\} = \int_{-2}^3 f(x)dx = \int_{-2}^0 f(x)dx + \int_0^2 f(x)dx + \int_2^3 f(x)dx = 1$

2) $P\{X > -2\} = \int_{-2}^{+\infty} f(x)dx = \int_{-2}^0 f(x)dx + \int_0^2 f(x)dx + \int_2^{+\infty} f(x)dx = 1$

b. Fonction de répartition**Définition 11**

Soit $f(x)$ une fonction de densité de probabilité de la variable aléatoire continue X , la fonction $F(x)$ telle que :

$$F(x) = P\{X \leq x\} = P\{-\infty < X \leq x\} = \int_{-\infty}^x f(t)dt .$$

Remarque

$F(x)$ est une primitive de $f(x)$:

$$f(x) = F'(x) .$$

Conséquence

$$P\{a < X < b\} = \int_a^b f(x)dx = F(b) - F(a) .$$

c. Espérance mathématique. Variance. Ecart-type**Définition 12**

Soit une variable aléatoire continue X de fonction de densité de probabilité $f(x)$ et dont l'intervalle de définition est $] -\infty, +\infty[$. L'espérance mathématique de X est définie par :

$$E(X) = \int_{-\infty}^{+\infty} x \cdot f(x)dx ,$$

sa variance par :

$$V(X) = E(X^2) - [E(X)]^2 ,$$

avec

$$E(X^2) = \int_{-\infty}^{+\infty} x^2 \cdot f(x)dx ,$$

son écart-type par

$$\sigma = \sqrt{V(X)} .$$

I. Lois fondamentales de probabilité.

0. Introduction

Les méthodes statistiques permettent généralement d'obtenir la distribution empirique ou expérimentale d'une variable aléatoire. Cependant, il est souvent utile, pour des raisons théoriques et pratiques, de pouvoir décrire une loi de probabilité par un modèle dit théorique.

1. Lois de probabilité discrètes

a. La loi binomiale

• Définitions

Définition 1

Une variable aléatoire discrète qui suit une loi binomiale est appelée variable aléatoire binomiale. Elle est la somme de n variables de Bernoulli.

Définition 2

On appelle variable de Bernoulli, une variable qui traduit 2 alternatives possibles : succès ou échec, avec les probabilités respectives p et q telles que $p + q = 1$.

Remarque

Une variable de Bernoulli ne peut prendre que 2 valeurs possibles :

$$X(\Omega) = \{0, 1\}.$$

Loi de probabilité

X	0	1
P	q	p

Caractéristiques

Espérance mathématique

$$E(X) = \sum x_i p_i = p$$

Variance

$$V(X) = E(X^2) - [E(X)]^2 = p - p^2 = p(1 - p) = p \cdot q$$

Définition 3

L'épreuve de Bernoulli est reproduite n fois ; la variable aléatoire X désigne le nombre de succès ou de réalisations d'un événement au cours des n épreuves indépendantes. On appelle loi binomiale la loi de distribution de la variable X , qui peut prendre $n+1$ valeurs : $0, 1, 2, \dots, n$, décrites par la formule de Bernoulli :

$$P\{X = k\} = C_n^k p^k q^{n-k} \quad (1)$$

On note

$$X \sim B(n, p)$$

-loi binomiale de paramètres n et p , où n –désigne le nombre d'épreuves et p –la probabilité de "succès".

- **Caractéristiques de la variable binomiale**

Espérance mathématique

$$E(X) = n \cdot p$$

Variance

$$V(X) = n \cdot p \cdot q$$

Ecart-type

$$\sigma(X) = \sqrt{n \cdot p \cdot q} .$$

Exemple

On lance une pièce de monnaie 100 fois. La variable aléatoire X désigne le nombre de "face" obtenu. Donner la loi de probabilité de X et ses caractéristiques.

Il s'agit d'une épreuve à 2 issues "pile" ou "face". Nombre d'épreuves

$n = 100$ et $p = \frac{1}{2}$. D'où

$$X \sim B(100, 1/2)$$

On a

Espérance mathématique

$$E(X) = 100 \cdot 1/2 = 50$$

Variance

$$V(X) = 100 \cdot 1/2 \cdot 1/2 = 25$$

Ecart-type

$$\sigma(X) = \sqrt{100 \cdot 1/2 \cdot 1/2} = \sqrt{25} = 5$$

- **Domaines d'application**

1) Epreuves à 2 issues

2) Le schéma de l'urne dans laquelle on effectue n tirages successifs avec remise.

b. Loi de Poisson

Définition 4

Soit une variable aléatoire discrète X et λ un nombre réel strictement positif ($\lambda > 0$)

X est appelé variable de Poisson, si sa loi de probabilité est définie par :

$$P(k) \equiv P\{X = k\} = e^{-\lambda} \frac{\lambda^k}{k!} , \quad k = 0, 1, 2, \dots$$

où λ est une constante donnée appelée paramètre de Poisson.

Exercice

Montrer que

$$\sum_{k=0}^{+\infty} P(k) = 1 ?$$

En effet

$$\sum_{k=0}^{+\infty} P(k) = \sum_{k=0}^{+\infty} e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{+\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda} = e^0 = 1 .$$

- **Caractéristiques**

Espérance mathématique

$$E(X) = \lambda$$

Variance

$$V(X) = \lambda$$

Ecart-type

$$\sigma(X) = \sqrt{\lambda} .$$

Remarque

Le paramètre de la loi de poisson λ est à la fois l'espérance mathématique et la variance :
X obéit à une loi de Poisson si et seulement si :

$$E(X) = V(X) = \lambda .$$

• **Domaines d'application**

- 1) La loi de Poisson permet de décrire le nombre de réalisations d'un événement donné, dont la probabilité est faible. Elle est aussi appelée loi des événements rares. Elle permet de décrire les phénomènes suivants :
 - le nombre de défauts que comporte un article fabriqué en série ;
 - le nombre d'accidents se produisant dans une usine au cours d'une période donnée.
- 2) La loi de Poisson intervient dans une classe importante de processus aléatoires, appelés processus de Poisson. Leur existence est basée sur la réunion des conditions suivantes :
 - La probabilité de réalisations de l'événement considéré, au cours d'un intervalle de temps infiniment petit (d t) est proportionnelle à sa durée ;
 - Cette probabilité est indépendante du nombre de réalisations antérieures de l'événement et demeure constante au cours de la période d'observation ;
 - La probabilité que l'événement se réalise plus d'une fois dans le même intervalle de temps d t est négligeable. Ainsi, le nombre X d'événements réalisés au cours d'un intervalle de temps T est une variable de Poisson de paramètre : $\lambda = n \cdot p$, avec $n = \frac{T}{dt}$ et p le nombre constant de réalisations au cours de l'intervalle de temps d t.

Exemples

- Nombre d'appels téléphoniques à un standard ;
- File d'attente : nombre de clients à un guichet, nombre de passagers à un arrêt de bus, nombre de malades à un service d'urgence.

• **Approximation de la loi binomiale par la loi de Poisson**

Soit X une variable aléatoire binomiale :

$$X \sim B(n, p) .$$

Si

$$n \rightarrow \infty \text{ et } p \rightarrow 0 ,$$

alors

$$n \cdot p \rightarrow \lambda ,$$

et la loi binomiale peut être approximée par la loi de Poisson de paramètre

$$\lambda = n \cdot p \text{ et}$$

$$B(n, p) \rightarrow P(\lambda) .$$

En pratique, la substitution de la loi binomiale par la loi de poisson se fait pour $n \geq 50$ et $p \leq 0,1$.

Remarque

L'espérance mathématique de la loi de Poisson est égale à l'espérance mathématique de la loi binomiale : $\lambda = n \cdot p$.

C'est le nombre moyen de réalisations d'un événement donné, au cours de n expériences.

2. Lois de probabilité continues

a. La loi exponentielle

Définition 1

Soit α un nombre réel strictement positif ($\alpha > 0$). $\varepsilon(\alpha)$ est une loi exponentielle de X de paramètre α , si X admet une fonction de densité de probabilité définie par :

$$f(x) = \begin{cases} \alpha e^{-\alpha x}, & x \geq 0 \\ 0, & x < 0 \end{cases}.$$

Exercice

- 1) Montrer que f est une fonction de densité de probabilité $\forall \alpha > 0$.
- 2) Donner la fonction de répartition de X .
- 3) Calculer les caractéristiques de X .

b. La loi normale

• Définition

Définition 2

On dit qu'une variable aléatoire continue X obéit à une loi normale de moyenne m et d'écart-type σ , si sa fonction de densité de probabilité $f(x)$ est définie par :

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left[\frac{x-m}{\sigma}\right]^2}, \quad -\infty < x < +\infty$$

(loi de Laplace-Gauss).

On note

$$X \sim N(m, \sigma).$$

• Fonction de répartition

$$F(x) = P\{X \leq x\} = \int_{-\infty}^x \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left[\frac{s-m}{\sigma}\right]^2} ds = F(x, m, \sigma).$$

• Représentation

(figure)

• Loi normale centrée réduite

Soit T la variable aléatoire obtenue à partir de X par le changement de variable suivant :

$$T = \frac{X-m}{\sigma}.$$

T obéit à une loi normale :

- centrée, car $E(T) = 0$;
- réduite, car $\sigma(T) = 1$.

Par conséquent

$$T \sim N(0,1),$$

et sa fonction de densité de probabilité est définie par :

$$f(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}t^2}.$$

- **Représentation**

(figure)

- **Fonction de répartition de T**

La fonction de répartition de la variable aléatoire T est notée $\pi(t)$:

$$\pi(t) = P\{T < t\} = \int_{-\infty}^t \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}s^2} ds .$$

Remarques

- 1) Les valeurs de $f(t)$ et $\pi(t)$ sont tabulées pour des valeurs de $t > 0$ (table de la loi normale) ;
- 2) $f(-t_0) = f(t_0)$;
- 3) $\pi(-t_0) = 1 - \pi(t_0)$
- 4) $P\{t_1 < T < t_2\} = \pi(t_2) - \pi(t_1)$;
- 5) $P\{|T| < t_0\} = P\{-t_0 < T < t_0\} = 2\pi(t_0) - 1$.

Exemple

La taille d'une population est distribuée normalement avec une moyenne de 165 cm et un écart-type de 15 cm. Déterminer la probabilité que la taille d'un individu soit :

- a) *inférieure à 150 cm ;*
- b) *inférieure ou égale à 175 cm ;*
- c) *supérieure à 175 cm ;*
- d) *comprise entre 150 et 170 cm .*

La variable aléatoire X désigne la taille de la population avec $m = 165$ et $\sigma = 15$:

$$X \sim N(165, 15) .$$

Donc

$$T = \frac{X-165}{15}$$

- a) $P\{X < 150\} = P\left\{T < \frac{150-165}{15}\right\} = P\{T < -1\} = \pi(-1) = 1 - \pi(1) = 1 - 0,8713 = 0,1287$.
- b) $P\{X \leq 175\} = P\left\{T \leq \frac{175-165}{15}\right\} = P\{T \leq 0,67\} = \pi(0,67) = 0,7486$
- c) $P\{X > 175\} = P\left\{T > \frac{175-165}{15}\right\} = P\{T > 0,67\} = 1 - P\{T \leq 0,67\} = 1 - \pi(0,67) = 1 - 0,7486 = 0,2514$.
- d) $P\{150 \leq X \leq 170\} = P\left\{\frac{150-165}{15} \leq T \leq \frac{170-165}{15}\right\} = P\{-1 \leq T \leq 0,33\} = \pi(0,33) - \pi(-1) = 0,6293 - 0,1287 = 0,5006$

c. **Approximation par la loi normale**

- **Approximation de la loi binomiale**

Soit X une variable aléatoire binomiale

$$X \sim B(n, p) .$$

Si $n \rightarrow \infty$, alors $T \sim N(0,1)$ avec

$$T = \frac{X-np}{\sqrt{npq}} .$$

Dans la pratique, cette approximation se fait dès lors que $n \geq 30$.

- **Approximation de la loi de Poisson**

Soit X une variable aléatoire binomiale

$$X \sim B(n, p).$$

Si $\lambda \rightarrow \infty$, alors $T \sim N(0,1)$ avec

$$T = \frac{X - \lambda}{\sqrt{\lambda}}.$$

Dans la pratique, cette approximation se fait dès lors que $\lambda \geq 20$.

- **Tableau de correction de continuité**

L'approximation par la loi normale implique la substitution d'une variable discrète (la variable binomiale et la variable de Poisson) par une variable continue (la variable normale).

Les corrections qu'imposent le passage du discret au continu sont les suivantes :

Discret	Continu
$P\{X > x_i\}$	$P\left\{X > x_i + \frac{1}{2}\right\}$
$P\{X \geq x_i\}$	$P\left\{X \geq x_i - \frac{1}{2}\right\}$
$P\{X < x_i\}$	$P\left\{X < x_i - \frac{1}{2}\right\}$
$P\{X \leq x_i\}$	$P\left\{X < x_i + \frac{1}{2}\right\}$

Exemple

Une pièce de monnaie est lancée 100 fois. On désigne par X , le nombre de "pile" obtenu.

- Déterminer la loi de probabilité de X
- Calculer $E(X)$ et $V(X)$
- Calculer $P\{45 < X < 55\}$.
- Calculer $P\{X > 55\}$

- X désigne le nombre de "P" obtenu. X obéit à une loi binomiale. C'est une épreuve à 2 issues, avec $n = 100$ et $p = \frac{1}{2}$, d'où

$$X \sim B(100, 1/2).$$

- $E(X) = n.p = 100.1/2 = 50$
 $V(X) = n.p.q = 50.1/2 = 25$

- On a

$$P\{45 < X < 55\} = P\left\{45 + \frac{1}{2} < X < 55 - \frac{1}{2}\right\} = P\{45,5 < X < 54,5\};$$

$$T = \frac{X - 50}{5}.$$

D'où

$$P\{45,5 < X < 54,5\} = P\left\{\frac{45,5 - 50}{5} < T < \frac{54,5 - 50}{5}\right\} = P\{-0,9 < T < 0,9\} = \pi(0,9) - \pi(-0,9) =$$

- $P\{X > 55\} = P\{X > 55 + 1/2\} = P\{X > 55,5\} = P\left\{T > \frac{55,5 - 50}{5}\right\} = P\{T > 1,1\} = 1 - P\{T \leq 1,1\} = 1 - \pi(1,1).$

CHAPITRE II

STATISTIQUES DESCRIPTIVES

INTRODUCTION

Beaucoup de disciplines scientifiques , expérimentales (chimie , physique , biologie , pharmacologie , médecine) ou humaines (sociologie , psychologie , économie , géographie etc.) ou encore les sciences sociales , le marketing , la finance , l'économétrie ont de plus en plus besoin des méthodes statistiques et ne sauraient s'en passer la plupart du temps . Celles-ci sont utilisées dans divers domaines tels que :

- Economie , assurance , finance : prévisions économétriques , analyse de la consommation des ménages , fixation des primes d'assurance , études quantitatives de marchés , gestion de portefeuille , évaluation d'actifs financiers , ...
- Biologie , médecine : essais thérapeutiques , épidémiologie , dynamique des populations .
- Science de la terre : prévisions météorologiques , exploration pétrolière .
- Science humaine : enquêtes d'opinion , sondages , étude des populations.

I-Définitions fondamentales ou Vocabulaire de base

1) La statistique et les statistiques

- La statistique peut être définie comme un ensemble de méthodes scientifiques utilisées dans la collecte , l'organisation , la présentation , l'analyse de données numériques , afin de commenter ou d'interpréter les faits auxquels ces données sont relatives .

- Les statistiques (*au pluriel*) peuvent être définie comme l'étude méthodique des faits sociaux qui définissent un état par des procédés numériques (dénombrements , inventaires , recensements , ..) . En d'autres termes , les

statistiques désignent les résultats numériques d'une enquête ou d'une série de mesures (après traitement éventuel par la statistique) .

- Il est souvent de coutume de distinguer la statistique descriptive qui concerne la collecte ,l'organisation et la présentation des données numériques, de l'inférence statistique ou la statistique inférentielle ou la statistique mathématique qui elle , traite de la manière par laquelle on tire des conclusions générales à propos d'un phénomène , sur la base de faits ou des données observées .

Ce cours porte essentiellement sur la statistique descriptive qui est une partie importante de la statistique .

2) Population ou Univers statistique

Une population , ou un univers statistique est un ensemble fini d'éléments , comme par exemple les infrastructures de santé au Canada en 1993 , les différents biens vendus par une épicerie au cours d'une période donnée , la population ivoirienne en 2015 , le personnel administratif à UPGC , le parc automobile à Korhogo etc.. .

La population en statistique n'est pas seulement un ensemble d'êtres humains (comme en démographie) , mais peut être aussi un ensemble d'objets concrets ou non . Tout simplement , la population statistique est l'ensemble étudié .

3) L'individu ou l'unité statistique ou l'unité d'observation

Un individu , ou une unité statistique , est un élément d'une population . Ainsi , un hôpital au Canada en 1993 , un bien vendu par une épicerie , un habitant de la Côte d'Ivoire en 2015 , sont des individus . Comme ces objets ou être humain, un évènement peut également être un individu .

- Sur ces unités statistiques , on mesure un caractère ou une variable .

4) Caractère ou Variable statistique

Le caractère , ou la variable statistique , est la propriété caractéristique d'un individu . Les variables sont désignées par simplicité par une lettre (X , Y , Z) .

Le coût de construction , le poids ou le prix d'un bien vendu par une épicerie , le sexe , le salaire , l'âge ou la religion d'un habitant de Côte d'Ivoire en 2015 sont des exemples de caractère .

Les valeurs possibles de la variable sont appelées modalités et l'ensemble des valeurs possibles ou l'ensemble des modalités est appelé le domaine de la variable . Si l'on considère le caractère ou la variable " sexe " , ses modalités sont masculin (codé M) et féminin (codé F) et le domaine de cette variable est $\{M, F\}$.

5) Distribution statistique ou Série statistique

Une distribution statistique , ou une série statistique , est l'ensemble des modalités d'un caractère et des effectifs des individus correspondants . Elle répartit la population suivant le caractère . Elle se présente généralement sous la forme d'un tableau appelé tableau statistique ou distribution de P selon X où P représente la population et X le caractère :

X_i	n_i
X_1	n_1
X_2	n_2
$\vdots$	$\vdots$
X_k	n_k
Total	N

X_i représente les modalités de X et n_i , le nombre d'individus (ou l'effectif ou la pondération) . n_i est le nombre de fois que la modalité se répète ou apparait et N est le nombre total d'individus ou l'effectif total : $N = \sum_{i=1}^k n_i$.

X_i peut prendre des valeurs négatives ou positives .

Exemple : La température dans le monde . Ici X_i peut prendre des valeurs positives , nulles ou négatives .

6) *L'échantillon statistique*

Définition : L'échantillon statistique est un sous-ensemble extrait de la population totale , mais qui a les mêmes caractéristiques que la population totale . Sur ce sous-ensemble , l'on prendra des mesures qui serviront à produire des estimations sur l'ensemble de la population .

Remarque :

- Il faut que l'échantillon soit représentatif de la population . Un échantillon non représentatif est dit biaisé .
- Lorsqu'on observe une seule variable au cours du temps (ex : la température journalière) , on parle d'une série temporelle .

7) *Typologie des variables*

Il existe deux grandes catégories de variables déclinées en deux types :

a) Variable quantitative

C'est lorsque son observation est une quantité mesurée ou lorsque toutes ses valeurs possibles sont numériques ou tout simplement le caractère est quantitatif lorsque les différentes modalités sont des nombres .

Exemple : un coût de construction , le poids , le prix , l'âge, le nombre d'infractions sont des caractères quantitatifs car mesurables .

On distingue les variables quantitatives discrètes ou discontinues dont les valeurs possibles sont finies ou dénombrables ou des nombres isolés .

Le plus souvent , ces valeurs sont entières (des nombres entiers) .

Exemple : le nombre d'enfants par ménage , le nombre d'infractions .

Et les variables quantitatives continues qui peuvent prendre toutes les valeurs possibles d'un intervalle .

Exemple : taille , salaire , poids , âge .

b) Variable qualitative

C'est lorsque les modalités sont des catégories ou des codes ou tout simplement lorsque les différentes modalités ne sont pas des nombres .

Exemple : la situation matrimoniale ,le sexe , la nationalité, la mention au BAC , la religion .

Ici également , on parle de variable qualitative *ordinale* lorsque les modalités peuvent être ordonnées .

Exemple : la mention au BAC .

Et de variable qualitative *nominale* lorsque les modalités ne peuvent pas être ordonnées .

Exemple : le sexe , la situation matrimoniale (marié , célibataire , veuf , divorcé) .

Les graphiques décrivant les distributions statistiques diffèrent suivant que l'étude concerne :

- un caractère ou variable qualitatif
- un caractère quantitatif discret
- un caractère quantitatif continu
- une série chronologique .

1- Caractère qualitatif

Pour représenter graphiquement les distributions statistiques relatives à un caractère qualitatif , on utilise habituellement le diagramme en bâtons , le diagramme à secteurs et enfin le diagramme à bandes .

a) Diagramme en bâtons

Nous portons en abscisse les modalités , de façon arbitraire . Nous portons en ordonnée des segments dont la hauteur est proportionnelle aux effectifs (ou aux fréquences) de chaque modalité .


Nous appelons polygone statistique , la ligne obtenue en joignant les sommets des bâtons.

b) Le diagramme à secteurs

On l'appelle aussi le diagramme circulaire ou le camembert .

La population étudiée est représentée graphiquement par une surface circulaire ou semi-circulaire . Cette surface est découpée en autant de secteurs que le caractère étudié comporte de modalités . Chaque secteur a un angle (l'angle au centre) qui est proportionnel à l'effectif ou à la fréquence de la modalité qu'il représente .

$$\begin{aligned} & \text{angle de chaque modalité (en degrés)} \\ &= \frac{\text{effectif de chaque modalité}}{\text{effectif total}} \times 360 \end{aligned}$$



NB : Pour un diagramme semi-circulaire , l'effectif total correspond à un angle de 180

c) Le diagramme à bandes

On l'appelle aussi diagramme en barre ou diagramme à tuyaux d'orgue . Dans ce graphique , les sous populations relatives à chacune des modalités du caractère étudié , sont représentées par des bandes rectangulaires . Les bandes ont une base constante , que l'on place à des distances régulières les unes des autres et la hauteur (ou la longueur) de chacune d'elles est proportionnelle à l'effectif ou à la fréquence de la sous population correspondante .

-Les modalités de la variable sont placées sur une droite horizontale (Attention ! Ne pas orienter cette droite car les modalités ne sont pas mesurables et il n'y a donc pas de relation d'ordre entre elles) .

-Les effectifs (ou les fréquences) sont placés sur un axe vertical . La hauteur du tuyau est proportionnelle à l'effectif ou à la fréquence .

NB : Les tuyaux ont une certaine épaisseur pour qu'il n'y ait pas de confusion avec les diagrammes en bâtons .

2) Le caractère quantitatif discret

On illustre les distributions statistiques d'une population suivant les modalités d'un caractère quantitatif discret à l'aide de trois graphiques : la représentation graphique des effectifs ou des fréquences (le diagramme en bâtons) , la représentation graphique des effectifs ou des fréquences cumulées (la courbe cumulative) et le polygone des fréquences .

a) Le diagramme en bâtons

Les valeurs discrètes X_i prises par les variables sont placées sur l'axe des abscisses , et les effectifs (ou les fréquences) sur l'axe des ordonnées . La hauteur du bâtons est proportionnelle à l'effectif ou à la fréquence .

Remarque : La différence avec le cas qualitatif consiste en ce que les abscisses ici sont les valeurs de la variable statistique .

b) Le polygone des fréquences

Le polygone des fréquences d'un caractère quantitatif discret est la courbe qui joint les sommets des bâtons d'un diagramme en bâtons .

c) La courbe cumulative

La courbe cumulative est la courbe représentative des effectifs cumulés ou des fréquences cumulées . Elle représente la fonction cumulative où la fonction de répartition définie par $F(X_i) = F_i$, qui est une fonction en escalier pour une variable discrète pour $X_i \leq X \leq X_{i+1}$.

Pour tout X inférieur à la plus petite des valeurs prises par la variable statistique étudiée , $F(X) = 0$.

Pour tout X supérieur à la plus grande des valeurs prises par la variable statistique étudiée $F(X) = 1$ ou à $F(X) = N$.

Pour les variables discrètes , la courbe cumulative est celle d'une fonction en escalier .

3) Le caractère quantitatif continu

On illustre les distributions statistiques d'une population suivant les modalités d'un caractère quantitatif continu à l'aide de trois graphiques : la représentation graphique des effectifs ou des fréquences appelée l'histogramme , la représentation graphique des effectifs cumulés ou des fréquences relatives appelée la courbe cumulative et le polygone des fréquences .

a) L'histogramme


C'est un ensemble de rectangles . Chaque rectangle est associé à une classe et il a une surface proportionnelle à l'effectif ou à la fréquence de cette classe . Contrairement au diagramme en barre , avec lequel il ne faut pas le confondre , les rectangles qui composent l'histogramme ont une base qui est définie par l'amplitude de la classe qu'ils représentent et , de plus , ils sont collés les uns aux autres .

Parfois , les classes ont des amplitudes égales . C'est le cas le plus évident
Parfois , cependant , les amplitudes des classes sont différentes . Il faut alors opérer une correction des effectifs comme indiquée ci-après .

Deux cas sont à distinguer : le cas où les amplitudes sont égales et le cas où les amplitudes sont inégales .

** Cas où les amplitudes sont égales*

La sous population relative à chaque modalité est représenté par un rectangle dont la longueur est égale à l'effectif ou à la fréquence relative correspondante.



* Cas où les amplitudes sont inégales

Si les amplitudes sont inégales , deux voies s'offrent à nous .

Nous pouvons construire l'histogramme en calculant la densité ou en corrigeant les effectifs .

- Par le calcul de la densité

$$d_i = \frac{n_i}{a_i} \text{ avec } d_i = \text{la densité}$$

n_i = les effectifs

a_i = les amplitudes

L'histogramme a pour abscisse la variable et en ordonnée les densité (d_i) .

- Par les effectifs corrigés

Si a'_i est l'amplitude la plus courante et la plus petite ou l'amplitude qui se répète le plus et n'_i l'effectif corrigé , on a :

$$n'_i = \frac{a'_i}{a_i} \times n_i$$

L'histogramme a pour abscisse la variable et en ordonnée les effectifs corrigés .

b) La courbe cumulative

De meme que dans le cas du caractère quantitatif discret , la courbe cumulative est la courbe représentative de la fonction F telle que $F(X)$ est égale à la proportion des individus pour lesquels la valeur du caractère est inférieur à X . La courbe cumulative est obtenue en plaçant chaque fréquence cumulée en face de l'extrémité de la classe correspondante .

c) Le polygone de fréquence

Le polygone de fréquence d'un caractère quantitatif continu est la courbe qui joint les milieux des rectangles d'un histogramme .

LES CARACTERISTIQUES D'UNE DISTRIBUTION UNIDIMENSIONNELLE

La distribution statistique unidimensionnelle est une distribution qui analyse un seul caractère ou une seule variable . Les caractéristiques d'une telle distribution sont :

- Les caractéristiques de tendance centrale
- Les caractéristiques de dispersion
- Les caractéristiques de position
- Les caractéristiques de forme
- Les caractéristiques de concentration

Les caractéristiques de tendance centrale sont : le mode (Mo) , la moyenne ($\bar{X}$) et la médiane (Me) .

1) La moyenne

La moyenne ne peut être définie que sur une variable quantitative . En revanche , on ne peut déterminer la moyenne lorsque la variable est qualitative car les différentes modalités de cette variable ne sont pas des nombres .

* Moyenne arithmétique

La moyenne arithmétique ne s'applique qu'aux variables qui admettent les opérations d'addition et de soustraction . Elle ne s'applique donc qu'aux variables quantitatives discrètes ou continues .

A) Cas d'une distribution quantitative discrète

a) Moyenne arithmétique pondérée

* Moyenne arithmétique pondérée par les effectifs

Pour le calcul :

- On multiplie chaque valeur X_i par l'effectif n_i correspondant et on effectue la somme des produits obtenus .

- On effectue le quotient de cette somme par l'effectif total

$$\bar{X} = \frac{1}{N} \sum_{i=1}^n n_i X_i \text{ avec } N = \text{effectif total ou taille de la population}$$

* Moyenne arithmétique pondérée par les fréquences

En remplaçant les effectifs n_i par les fréquences $f_i = \frac{n_i}{N}$, nous pouvons écrire $\bar{X} = \sum_{i=1}^n f_i X_i$

b) Moyenne arithmétique simple

La moyenne arithmétique simple de n valeurs ou éléments

$$X_1, X_2, \dots, X_n \text{ est : } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i .$$

NB: La moyenne arithmétique simple est donc une moyenne arithmétique pondérée pour laquelle les coefficients ou les pondérations sont toutes identiques ou uniformes .

B) Cas d'une distribution quantitative continue

Pour une série regroupée en classes , on obtient une valeur approchée de la moyenne arithmétique de la série en prenant pour X_i les centres des classes ou des intervalles . Ce centre est obtenu en faisant la moyenne des deux extrémités de chaque classe . $C_i = \frac{X_{i-1} + X_i}{2}$

$$\bar{X} = \frac{1}{N} \sum_{i=1}^k n_i C_i = \sum_{i=1}^k f_i C_i$$

* Mélange de population

Soit une population de taille N . Cette population est divisée en plusieurs sous populations de taille et de moyenne connues . Connaissant les moyennes des sous populations , quelle est la moyenne de la population mère ?

$$\bar{X} = \frac{n_1 \bar{X}_1 + n_2 \bar{X}_2 + \dots + n_n \bar{X}_n}{n_1 + n_2 + \dots + n_n}$$

où $\bar{X}$ est la moyenne de la population mère ;

$\bar{X}_1, n_1$ sont respectivement la moyenne et la taille de la sous population1 .

⋮
⋮

$\bar{X}_n, n_n$ sont respectivement la moyenne et la taille de la sous population n .

2) Généralisation de la notion de moyenne

a) Moyenne géométrique

Pour obtenir les valeurs moyennes sur le taux de croissance , les indices de prix et des taux d'intérêt , la moyenne arithmétique ne permet pas d'obtenir les valeurs exactes , il faut utiliser la moyenne géométrique comme caractéristique de tendance centrale .

* Moyenne géométrique pondérée

Soit une série statistique (X_i, n_i) avec $N = n_1 + \dots + n_n$

$$\bar{X}_G = G = \left(\prod_{i=1}^n X_i^{n_i} \right)^{1/N}$$

$$\Rightarrow \bar{X}_G = G = \exp \left[\frac{1}{N} \sum_{i=1}^n n_i \ln X_i \right]$$

* Moyenne géométrique simple

C'est le cas où tous les coefficients sont égaux et les $X_1, \dots, X_n$ sont les valeurs d'observations .

$$\bar{X}_G = \left(\prod_{i=1}^n X_i \right)^{1/n}$$

b) La moyenne harmonique

Elle est généralement utilisée pour les taux d'échange , les indices boursiers et les vitesses . Elle est notée H ou $\bar{X}_h$.

* Moyenne harmonique pondérée

La moyenne harmonique pondérée d'une série de n valeurs $X_1, \dots, X_n$ dont les coefficients respectifs est la suite de nombre suivante :

$n_1, \dots, n_n$ est :

$$H = \bar{X}_h = \frac{N}{\sum_{i=1}^n \frac{n_i}{X_i}}$$

* Moyenne harmonique simple

C'est lorsque tous les coefficients sont égaux .

$$H = \bar{X}_h = \frac{n}{\frac{1}{X_1} + \dots + \frac{1}{X_n}}$$

c) La moyenne quadratique

Elle est surtout utilisée pour mesurer la moyenne des aires . Elle est notée Q ou $\bar{X}_q$ est la racine carrée de la moyenne des carrés des n valeurs .

* Moyenne quadratique simple

C'est le cas où les n_i sont uniformes .

$$Q = \bar{X}_q = \sqrt{\frac{\sum X_i^2}{n}}$$

* Moyenne quadratique pondérée

$$Q = \bar{X}_q = \sqrt{\frac{\sum n_i X_i^2}{N}} \quad \text{où les } n_i \text{ sont les effectifs et}$$

$$N = n_1 + \dots + n_n .$$

3) Utilité des moyennes

- La moyenne arithmétique $\bar{X}$ est une unité (seuil) qui permet d'apprécier une série statistique étudiée présentant des valeurs très dispersées . Le plus souvent , la moyenne pertinente est la moyenne arithmétique .

Remarque : La moyenne est très sensibles aux valeurs extrêmes .

4) Relation entre les différentes moyennes

Si on utilise les mêmes données statistiques , on a la relation suivante :

$$H < G < \bar{X} < Q .$$

Exercice : Dans une classe , 20% des élèves ont eu 15 à un devoir , 50% ont eu 10 et 30% ont eu 8 .

Quelle est la moyenne de la classe ?

5) Le Mode

1) Définition

Le mode est la valeur du caractère observé avec la plus grande fréquence c'est à dire la valeur de la variable qui a le plus grand effectif ou la fréquence la plus élevée . Il est noté Mo et est parfois appelé Valeur dominante . Le mode est le seul paramètre de tendance centrale qui s'applique à tous les types de variables , qu'elles soient qualitatives ou quantitatives .

2) Détermination du mode

A) Variable quantitative

a) Cas d'une variable quantitative discrète

Le mode se détermine facilement et avec précision . Sa valeur s'obtient à partir du tableau statistique ou du diagramme en bâtons .

b) Cas d'une variable quantitative continue

Pour une variable quantitative continue , on parle de classe modale : c'est la classe dont l'effectif est maximum . Et dans ce cas , on doit distinguer deux cas de figure :

* Premier cas : les amplitudes sont égales

Si pour une distribution à amplitudes égales , la classe modale est :

$$M_o \in [X_{i-1}; X_i[\rightarrow n_i$$

n_{i-1} above X_{i-1} and n_{i+1} below X_i

avec n_i l'effectif le plus élevé .

- Mode avec peu de précision : $M_o = \frac{X_{i-1} + X_i}{2}$

- Mode avec beaucoup de précision

$$M_o = X_{i-1} + \frac{n_i - n_{i-1}}{(n_i - n_{i-1}) + (n_i - n_{i+1})} (X_i - X_{i-1})$$

* Deuxième cas : les amplitudes sont inégales

Lorsque les amplitudes ne sont pas égales , alors deux voies s'offrent à nous . Nous pouvons calculer le mode en utilisant la densité (d_i) ou par la correction des effectifs .

- Par le calcul de la densité (d_i ou h_i)

d_i ou $h_i = \frac{n_i}{a_i}$ avec d_i = la densité

n_i = les effectifs

a_i = les amplitudes .

La classe modale est la classe qui a la densité la plus élevée .

$$M_o \in [X_{i-1}; X_i[\rightarrow d_i$$

d_{i-1} above X_{i-1} and d_{i+1} below X_i

- Mode avec peu de précision : $M_o = \frac{X_{i-1} + X_i}{2}$

- Mode avec beaucoup de précision

$$M_o = X_{i-1} + \frac{d_i - d_{i-1}}{(d_i - d_{i-1}) + (d_i - d_{i+1})} (X_i - X_{i-1})$$

* Par la correction des effectifs

Pour corriger les effectifs (n_i), on choisit l'amplitude la plus courante (a'_i) et la plus petite ou l'amplitude qui se répète le plus.

Une fois l'amplitude choisie, la correction des effectifs se fait selon la règle suivante :

$$n'_i = \frac{a'_i}{a_i} \times n_i \quad \text{avec } n'_i = \text{effectifs corrigés}$$

a'_i = amplitude choisie

a_i = amplitude de la classe

n_i = effectif de la classe

la classe modale étant la classe qui a l'effectif corrigé le plus élevé.

$$M_o \in [X_{i-1}; X_i[\rightarrow \begin{matrix} n'_{i-1} \\ n'_i \\ n'_{i+1} \end{matrix}$$

- Mode avec peu de précision : $M_o = \frac{X_{i-1} + X_i}{2}$

- Mode avec beaucoup de précision est :

$$M_o = X_{i-1} + \frac{n'_i - n'_{i-1}}{(n'_i - n'_{i-1}) + (n'_i - n'_{i+1})} (X_i - X_{i-1})$$

Remarques

a) Une série peut avoir plusieurs modes

Soit $S = \{4; 0; 1; 1; 2; 2; 2; 3; 3; 4; 2; 3; 4; 5; 2; 1; 3; 3; 4; 5\}$

Cette série a deux modes, elle est bimodale. Ses deux modes sont : 2 et 3.

b) Le mode n'existe pas forcément

C'est le cas lorsque toutes les valeurs ont le même effectif (c'est à dire chaque valeur de la variable apparait une seule fois) . Dans ce cas , on peut aussi dire que toutes les valeurs sont modales .

c) Le mode n'est pas la valeur la plus élevée

Il ne faut pas confondre le mode , qui est la valeur la plus fréquente , avec la valeur la plus élevée de la série .

Dans la série {8; 6; 5; 7; 3; 1} , il n'y a pas de mode , mais la valeur la plus élevée est 8 . Il peut arriver que le mode soit aussi la valeur la plus élevée, mais ce n'est alors qu'une coïncidence .

* *Le mode présente plusieurs avantages :*

- Il est défini pour tous les types de variables
- Il est facile à déterminer .
- Il donne une première idée de la tendance centrale de la série .

* *Le mode présente aussi plusieurs inconvénients*

- Il n'a de sens que dans le cas d'un faible nombre de modalités .
- Il ne prend en compte qu'une seule valeur ou une seule classe , il est donc peu représentatif de l'ensemble .
- Il n'est pas nécessairement unique ; il arrive fréquemment que des distributions présentent deux ou plusieurs modes . On parle alors de distribution bimodale ou plurimodale (multimodale) contrairement à la moyenne et à la médiane .

B) Variable qualitative

La variable qualitative a des modalités qui ne s'expriment pas sous forme de nombre .

Détermination de son mode

Il suffit de regarder la distribution statistique et la valeur modale est celle qui a l'effectif le plus élevé .

6) La médiane

Définition : La médiane est la valeur du caractère pour lequel il y a autant d'observations ayant une valeur supérieure que d'observations ayant une valeur inférieure . En d'autres termes , c'est le nombre qui permet de couper la population étudiée (ou une série

statistique) en deux groupes contenant le même nombre d'individus (ou en deux sous groupes égaux) . Elle est notée Me .

La médiane peut être calculée sur des variables quantitatives et sur des variables qualitatives ordinales . Pour les variables qualitatives nominales , il est impossible de définir une médiane .

1) Détermination de la médiane

a) Cas d'une distribution quantitative discrète

X_i	n_i	$N_i \nearrow$
X_1	n_1	n_1
X_2	n_2	$n_1 + n_2$
$\vdots$	$\vdots$	$\vdots$
X_4	n_4	$N/2$
$\vdots$	$\vdots$	
X_k	n_k	N

$$Rang(Me) = \frac{N}{2} , \quad Me = X_4$$

b) Cas d'une distribution quantitative continue

Ici la variable est représentée sous forme de classe . La médiane s'obtient par la méthode d'interpolation linéaire . Elle est la valeur pour laquelle la fréquence cumulée est de 50% . On suppose que les effectifs sont uniformément repartis à l'intérieur des classes .

Sa formule est :

$$Me = X_{i-1} + \left[\frac{a_i}{f_i} (50 - F_c(X_{i-1})) \right]$$

avec X_{i-1} = borne inférieure de la classe médiane

a_i = amplitude de la classe médiane

f_i = fréquence de la classe médiane , $f_i = \frac{n_i}{N} \times 100$.

$F_c(X_{i-1})$ = fréquence cumulée croissante de la classe précédente jusqu'à son extrémité inférieure .

2) Intérêt ou avantage de la médiane

La médiane présente plusieurs avantages .

- Elle est facile à déterminer et sa signification est claire
- Elle part du classement de toutes les observations ; elle est donc représentative de l'ensemble .
- Elle est unique car chaque série n'a qu'une et une seule médiane .
- Elle est insensible aux valeurs extrêmes , ce qui en fait un paramètre remarquablement stable .

Résumer une distribution statistique à l'aide des caractéristiques de tendance centrale est nécessaire , mais insuffisant . Dans cette partie , nous allons retenir les principaux indicateurs qui sont au nombre de quatre :

- la variance
- le coefficient de variation
- l'étendue
- l'écart-type
- l'écart moyen absolu .

1) La variance

La variance est une mesure servant à caractériser la dispersion d'un échantillon ou d'une distribution . Elle indique de quelle manière la série statistique se disperse autour de sa moyenne . La variance est toujours positive ou nulle . Elle se calcule sur les distributions quantitatives continues ou discrètes (on exclut les variables qualitatives) .

Si les effectifs ne sont pas uniformes , on a :

$$V(X) = \frac{1}{N} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{N} \sum_{i=1}^n n_i X_i^2 - \bar{X}^2$$

* Propriétés de la variance

- Variance d'une combinaison linéaire de deux variables

Soit $Z = aX + bY + c$ c'est à dire

$$\forall i \quad Z_i = aX_i + bY_i + c$$

$$V(Z) = a^2V(X) + b^2V(Y) + 2ab \operatorname{cov}(X, Y)$$

Si X et Y sont indépendantes , alors $\operatorname{cov}(X, Y) = 0$.

$$\Rightarrow V(Z) = a^2V(X) + b^2V(Y)$$

Si $Z = aX + b$ alors $V(Z) = a^2V(X)$

Pour toute constante a , $V(a) = 0$.

Remarques :

- Si la variance est nulle , cela signifie que toutes les valeurs sont identiques et par conséquent la distribution concernée n'est pas dispersée . Une petite variance est signe que les valeurs sont proches les unes des autres alors qu'une variance élevée est signe que celles-ci sont très écartées .
- La moyenne des variances $(\overline{V(X)})$ d'un mélange de population est appelée variance intra population .
- La variance des moyennes $(V(\bar{X}))$ dans le cas d'un mélange de population est appelée variance inter population .

Conclusion partielle

La variance est la première caractéristique de dispersion . Elle s'exprime dans la même unité que la variable , mais ne permet pas de comparer la dispersion de plusieurs distributions qui s'expriment dans les unités différentes . Force de cet inconvénient , on va utiliser un autre indicateur de dispersion qui va permettre de résoudre le problème de la variance . C'est le coefficient de variation .

2) Le coefficient de variation (CV)

Il vient donc combler les lacunes de la variance .

Sa formule est : $CV = \frac{\sigma_X}{\bar{X}}$ avec $\bar{X} \neq 0$ et σ_X = écart-type .

C'est un nombre sans unité ou sans dimension . Il permet de comparer la dispersion de deux ou plusieurs distributions qui ne s'expriment pas dans la même unité et dont leurs moyennes ne sont pas du même ordre de grandeur .

3) L'étendue

L'étendue est une caractéristique de dispersion qui apparemment est facile à calculer . Elle est simplement la différence entre la plus grande et la plus petite valeur observée .

D'où sa formule : $e = X_{i \max} - X_{i \min}$

L'étendue s'exprime dans la même unité que la variable , mais en pratique sa détermination rencontre quelque fois des problèmes car on n'a pas toujours les informations sur les valeurs extrêmes de la distribution .

4) L'écart absolu moyen

L'écart absolu moyen est autre indicateur de dispersion . Il permet de mesurer la dispersion des observations par rapport à l'élément moyen . Il s'exprime toujours dans la même unité que la variable et est toujours positif .

$e_{\bar{X}} = \frac{1}{N} \sum_{i=1}^k n_i |X_i - \bar{X}|$ où les n_i sont les pondérations ou les effectifs .

et $e_{\bar{X}} = \frac{1}{N} \sum_{i=1}^k |X_i - \bar{X}|$ lorsque les pondérations sont uniformes et égales à 1 .

5) L'écart-type

Il est exprimé dans la même unité que la variable . La variance est , elle, mesurée dans l'unité au carré .

Sa formule est : $\sigma = \sqrt{V}$.

1) Les quartiles

a) Définition

Les quartiles sont les valeurs de la variable qui partagent la série en 4 sous-ensembles de même effectif . Il y a trois quartiles :

$$Q_1(F(Q_1) = 25\%) , \quad Q_2(F(Q_2) = 50\%) \text{ et } Q_3(F(Q_3) = 75\%)$$

On appelle premier quartile d'une série la plus petite valeur Q_1 des termes de la série pour laquelle au moins 25% des données sont inférieures ou égales à Q_1 .

On appelle troisième quartile d'une série la plus petite valeur Q_3 des termes de la série pour laquelle au moins 75% des données sont inférieures ou égales à Q_3 .

On appelle intervalle interquartile l'intervalle $[Q_1; Q_3]$.

On appelle écart interquartile le nombre $Q_3 - Q_1 = IQ$.

b) Détermination des quartiles

- Cas d'une variable discrète

Le 1er quartile et le 3e quartile d'une série statistique rangée dans l'ordre croissant sont les nombres Q_1 et Q_3 définie de la façon suivante :

- Si $\frac{N}{4}$ est un entier , le 1er quartile Q_1 est le terme de rang $\frac{N}{4}$ avec $F(Q_1) = 25\%$ et le 3e quartile est le terme de rang $\frac{3N}{4}$ avec $F(Q_3) = 75\%$.

- Si $\frac{N}{4}$ n'est pas un entier , Q_1 et Q_3 sont respectivement les termes de rang immédiatement supérieur à $\frac{N}{4}$ et à $\frac{3N}{4}$.

2) Les déciles

a) Définition

Les déciles sont les valeurs de la variable qui partagent la série en 10 sous-ensembles de même effectif. Il y a 9 déciles : $D_1, \dots, D_9$.

- On appelle premier décile d'une série la plus petite valeur D_1 des termes de la série pour laquelle au moins un dixième (10%) des données sont inférieures ou égales à D_1 .

- On appelle neuvième décile d'une série la plus petite valeur D_9 des termes de la série pour laquelle au moins 90% des données sont inférieures ou égales à D_9 .

- On appelle intervalle interdécile l'intervalle $[D_1; D_9]$.

- On appelle écart interdécile le nombre $D_9 - D_1$.

Remarque : $D_5 = Me$

3) Les centiles ou percentiles

a) Définition

Les (per) centiles sont les valeurs de la variable qui partagent la série en 100 sous-ensembles de même effectif. Il y a 99 centiles : $P_1, \dots, P_{99}$.

b) Détermination

* Cas des variables discrètes

Les quantiles se déterminent de la même façon que la médiane.

* Cas des variables continues

Ici même type de formule que pour la médiane.

Illustration avec les quartiles

On détermine les classes qui contiennent chaque quartile.

$$Q_1 = \text{extre inf. cl}(Q_1) + \text{ampl cl}(Q_1) \times \left(\frac{25\% - \text{fre. cum}}{\text{fre cl}(Q_1)} \right)$$

$$Q_3 = \text{extr inf. cl}(Q_3) + \text{ampl cl}(Q_3) \cdot \left(\frac{75\% - \text{fre cum}}{\text{fre cl}(Q_3)} \right)$$

NB : Certains quantiles ont des noms spéciaux

- Les quintiles : (5 groupes : 20% des effectifs chacun)

- Les vingtiles : (20 groupes : 5% des effectifs chacun)

4) Représentation graphique

On utilise la boîte à moustache pour représenter graphiquement l'intervalle interquartile .

5) La boîte à moustache

On l'appelle encore boxplot ou boîte de dispersion ou diagramme de Tukey ou boîte à pattes .

a) Définition

La boîte à moustache de l'Anglais « Box and Whiskers » est un graphique qui résume la dispersion d'une série à partir de 5 valeurs : la valeur minimale et la valeur maximale (ce sont les moustaches) , l'intervalle interquartile (désigné par ses deux valeurs Q_1 et Q_3) et la médiane (ces trois dernières valeurs constituent la boîte) .

b) Construction de la boîte à moustache

- Sur un axe horizontal (ou vertical) , on place les 5 valeurs suivantes : le minimum , le maximum , la médiane , le 1^{er} quartile et le 3^e quartile .
- On construit un rectangle horizontal (ou vertical) allant de Q_1 à Q_3 . Son grand côté est donc égal à l'écart interquartile $Q_3 - Q_1$.
- Ce rectangle est séparé par un segment passant par la médiane .
- On ajoute ensuite deux segments : l'un allant de Q_1 au minimum et l'autre allant de Q_3 au maximum .

c) Utilité de la boîte à moustache pour déterminer la forme d'une distribution

La boîte à moustache permet de comparer des séries du point de vue de leur dispersion mais aussi de leur caractéristique de tendance centrale (puisque la médiane est repérée) .

Suivant la position de la médiane au sein de la boîte , on peut en déduire des informations sur la forme de la distribution .

- Si la médiane est proche du centre de la boîte , c'est que la distribution est symétrique .
- Si la médiane est à gauche du centre de la boîte , on a une distribution étalée à droite .

- Si la médiane est à droite du centre de la boîte , alors on a une distribution étalée à gauche .

De même , en comparant la longueur respective de chaque moustache , on peut en déduire des informations sur la forme de la distribution .

- Si les moustaches sont à peu près de la même longueur , la distribution est symétrique .

- Si la moustache de droite est plus longue que la moustache de gauche , la distribution est étalée à droite .

- Si la moustache de gauche est plus longue que la moustache de droite , la distribution est étalée .

La concentration : c'est une notion importante en économie .

Définition : La concentration d'une distribution mesure sa répartition observée par rapport à une norme de répartition (la répartition à laquelle on s'attend) .

Ici , on cherchera à mesurer la concentration des salaires , des revenus , du chiffre d'affaires des entreprises , de l'emploi ...

1) La médiale

a) Définition

La médiale est la valeur de la variable qui partage la masse salariale ou la masse totale en deux parties égales lorsque la masse salariale ou la masse totale est rangée par ordre croissant ou décroissant .

La masse salariale est le total des revenus distribués , s'il s'agit d'autres éléments que les revenus , on parle de masse totale .

La médiale est un indicateur qui s'apparente à la médiane , mais appliquée à une série différente . En effet , alors que la médiane s'applique aux valeurs de la variable (les X_i) , la médiale s'applique aux valeurs de la variable multipliée par leurs effectifs respectifs (les $n_i X_i$) . C'est la valeur du caractère qui partage l'effectif cumulé des $n_i X_i$ en deux parties égales .

NB : La médiale (M_l) est donc la valeur de la variable pour laquelle la fréquence cumulée des $n_i X_i$ est égale à $1/2$.

b) Détermination de la médiale

- Cas d'une variable quantitative discrète

Dans le cas d'une distribution quantitative discrète , la médiale est déterminée par excès .

- Cas d'une variable quantitative continue

Ici , on suppose que la masse salariale ou la masse totale se répartit uniformément à l'intérieur des classes . La médiale se détermine par interpolation linéaire .

La formule de la masse salariale est : $\sum_{i=1}^k n_i X_i$ où

X_i =centre de classe

et n_i = effectifs ou pondérations .

Soit la série statistique ($X_i; n_i$) , on définit : $q_i = \frac{n_i X_i}{\sum_{i=1}^k n_i X_i}$,

$Q(x) = \sum_{i=1}^k q_i$.

La médiale (Ml) est telle que $Q(Ml) = 50\%$. On a la formule suivante :

$$Ml = e_{i-1} + \left[\frac{a_i}{q_i} (50 - Q(e_{i-1})) \right]$$

Exemple

X_i	[10; 30[	[30; 50[	[50; 70[	[70; 90[
n_i	24	16	14	6
c_i	20	40	60	80

2) La courbe de Lorenz

Il s'agit de construire une figure appelée courbe de Lorenz ou courbe de concentration du nom de son inventeur qui cherchait un moyen commode de comparer les inégalités de revenu entre diverses populations . Elle peut aussi servir à mesurer d'autres formes d'inégalité que celle des revenus .

- La courbe de Lorenz se trace dans un carré de coté 1.
- En abscisse , figurent les fréquences relatives cumulées croissantes $F(x)$ de la variable .
- l'axe des abscisses va de 0 à 1 (ou de 0 à 100 %)
- Et en ordonnée figurent les fréquences cumulées croissantes de la masse salariale ($Q(x) = F(n_i X_i)$) .
- l'axe des ordonnées va de 0 à 1 (ou de 0 à 100 %) .

La courbe de Lorenz se trouve en deçà de la 1ere bissectrice . Plus la courbe de Lorenz est éloignée de la 1ere bissectrice , plus la distribution est concentrée , plus l'inégalité est grande .

- Plus au contraire , si elle se rapproche de la 1ere bissectrice , au moins la distribution est concentrée , l'inégalité est faible .

- Si la courbe de Lorenz se confond avec la diagonale , la répartition est dite égalitaire (concentration nulle) .
- Si la courbe de Lorenz est confondue aux axes , alors l'inégalité est très élevée .

Remarque :

Sur le graphique , on indique toujours la diagonale . Plus l'écart entre la courbe de Lorenz et la diagonale est important , plus les revenus sont distribués de manière inégalitaire .

La surface hachurée est appelée " aire de concentration " . On peut la mesurer par une formule appelée " Indice de concentration de Gini " ou plus communément " indice de Gini " .

3) L'indice de Gini (I_G)

L'indice de Gini mesure la concentration d'une distribution sur la base de la courbe de Lorenz . La surface entre la courbe et la 1ere bissectrice est l'aire de concentration .

Géométriquement , l'indice de Gini est égale à l'aire de concentration divisée par la moitié de la surface du carré :

$$I_G = \frac{\text{aire de concentration}}{\text{surface du triangle } OAB}$$

$$I_G = 2 \times \text{aire de concentration}$$

- Si l'on dispose de papier millimétré , on peut compter les petits carrés et avoir une idée approximative de la surface de l'aire de concentration . Mais il est préférable d'utiliser la formule analytique .

Détermination numérique de l'indice de Gini

$$I_G = 1 - \sum_{i=1}^k f_i(Q_{i-1} + Q_i)$$

où f_i = fréquence relative

Q_{i-1} = masse salariale relative cumulée de l'intervalle $i - 1$

et Q_i = masse salariale relative cumulée de l'intervalle i .

Il existe plusieurs méthodes de détermination numérique de l'indice de Gini . La plus courante est la méthode de trapèze .

$$I_G = \frac{\text{aire de concentration}}{\text{surface du triangle } OAB}$$

or , aire de concentration = aire de OAB - Z

$$= \frac{1 \times 1}{2} - Z = \frac{1}{2} - Z$$

$$I_G = \frac{\frac{1}{2} - Z}{\frac{1}{2}} = 1 - 2Z$$

où $Z = \text{aire du triangle} + \text{aire du trapèze1} + \text{aire du trapèze2}$

Remarque:

1) Indice de Gini : nombre sans dimension compris entre 0 et 1 .

$$0 \leq I_G \leq 1$$

2) $I_G = 0$ quand la surface de concentration est nulle (égalité parfaite) ; il y a une faible concentration .

3) $I_G = 1$ quand la surface de concentration est égale à la surface OAB (inégalité parfaite) ; il y a une forte concentration .

Propriétés de l'indice de Gini

L'indice de Gini est très utilisé pour mesurer les disparités de revenus (il constitue un indicateur d'inégalité) . Dans ce cadre , il possède des propriétés intéressantes :

- Il n'est pas modifié si tous les revenus varient d'un même pourcentage .
- Un transfert de revenu d'un individu riche vers un individu pauvre diminue la valeur de l'indice .

I-Opérations sur la Somme et le ProduitA) L'opérateur Somme

L'opérateur sigma sert à contracter l'écriture d'une somme de nombres . Il est noté $\sum$ (*lettre grecque sigma majuscule*) et est appelé signe sommatoire ou plus couramment signe somme .

Exemple 1

$$X_1 + X_2 + \dots + X_n = \sum_{i=1}^n X_i$$

Exemple 2

La somme des 10 premiers entiers naturels impairs :

$$S = \sum_{k=1}^{10} (2k + 1) = 1 + 3 + 5 + 7 + 9 + 11 + 13 + 15 + 17 + 19 = 100$$

-Propriétés de la somme

1-Pour tout réel a , on a : $\sum_{i=1}^n a = na$

Démonstration

$$\sum_{i=1}^n a = a + a + \dots + a = na$$

2-Linéarité

$$\sum_{i=1}^n \alpha X_i = \alpha \sum_{i=1}^n X_i \quad , \quad \forall \alpha \in \mathbb{R}$$

Démonstration

-Soient $X_1, X_2, \dots, X_n$ et $Y_1, Y_2, \dots, Y_n$: n réels , On a :

$$\sum_{i=1}^n (X_i + Y_i) = \sum_{i=1}^n X_i + \sum_{i=1}^n Y_i$$

3- Somme de produits

$$\sum_{i=1}^n X_i Y_i \neq \sum_{i=1}^n X_i \sum_{i=1}^n Y_i$$

B) L'opérateur produit

Pour exprimer un produit d'éléments de façon compacte, on utilise l'opérateur produit, symbolisé par la lettre grecque majuscule (Pi) : $\prod$

Exemple : Soit quatre valeurs d'une variable X , indicées par i , X_1, X_2, X_3 et X_4 . Le produit de ces 4 valeurs est donnée par l'expression :

$$\prod_{i=1}^4 X_i = X_1 \times X_2 \times X_3 \times X_4$$

-Propriétés du produit

1) $\forall a \in \mathbb{R}, \quad \prod_{i=1}^n a = a^n$

2) Linéarité

- $\prod_{i=1}^n \alpha X_i = \alpha^n \prod_{i=1}^n X_i$

- $\prod_{i=1}^n X_i Y_i = (\prod_{i=1}^n X_i)(\prod_{i=1}^n Y_i)$

3) Produit de sommes

$$\prod_{i=1}^n (X_i + Y_i) \neq \prod_{i=1}^n X_i + \prod_{i=1}^n Y_i$$

4)Autres règles de calcul

$$\prod_{i=1}^n X_i^n = (\prod_{i=1}^n X_i)^n \quad \text{pour } n \in \mathbb{R}.$$

Attention : On ne peut jamais mettre en facteur une expression dans un

Produit même si elle ne dépend pas de l'indice de sommation.

Autrement dit , en général $\prod_{i=1}^n \alpha X_i \neq \alpha \prod_{i=1}^n X_i$.

Remarque : changement d'indices

Dans les expressions de somme (ou de produit) vues précédemment, la lettre i est appelée indice de sommation (ou de produit) : c'est une variable muette .

Exemple : $\sum_{k=1}^n a_k = \sum_{i=1}^n a_i$

Cette remarque prend tout son sens dans le changement de variable .

II-Quelques sommes remarquables

A) Suites géométriques

1- Définition

On appelle suite géométrique une suite de nombres où on passe d'un terme au suivant en multipliant toujours par le même nombre (ce nombre est appelé raison de la suite géométrique et est souvent noté q).

On a alors $U_{n+1} = U_n q$ où q est la raison ($q \neq 0$).

2- Formule générale

Le terme de rang n est donné par l'expression $U_n = U_1 q^{(n-1)}$.

Remarque

- Si U_0 est le 1^{er} terme, alors $U_n = U_0 q^n$.

- Pour tout entier $p \leq n$, $U_n = U_p q^{(n-p)}$

3- Somme des n premiers termes d'une suite géométrique

$$S = \text{1er terme} \times \frac{q^{\text{nombre de termes}-1} - 1}{q - 1}$$

Théorème

Pour tout entier $n \in \mathbb{N}$ et tout réel $q \neq 1$,

$$1 + q + q^2 + \dots + q^n = \frac{1 - q^{n+1}}{1 - q}$$

Remarque

- Cette formule n'est pas valable pour $q = 1$. Mais dans ce cas, tous les termes de la somme valent 1 ; la somme est donc égale au nombre de termes $n + 1$.

- Si $U_0 + U_1 + \dots + U_n = U_0 \frac{1-q^{n+1}}{1-q}$

- La somme des k premiers termes d'une suite géométrique est :

$$S_k = U_1 + U_2 + \dots + U_k = U_1 \frac{1-q^k}{1-q} \quad (q \neq 1)$$

Exercices d'application : Calculer les sommes suivantes

1) $S = 1 - \frac{1}{2} + \frac{1}{4} + \dots + \left(-\frac{1}{2}\right)^{1998}$

2) $S = (-x) + x^2 - x^3 + \dots + (-x)^{17}$

Exercice à faire à la maison

Calculer la somme suivante : $S_1 = \sum_{k=3}^{n-1} 2^k$